文章编号:1006-9348(2023)01-0137-06

高速公路上无人驾驶汽车目标检测算法的研究

葛 雯,马 乐,屈乐乐
(沈阳航空航天大学电子信息工程学院,辽宁 沈阳 110136)

摘要:为了解决高速公路环境下无人驾驶汽车对目标检测准确度及速度的问题,提出一种改进SSD模型的目标检测算法,通过结合空洞卷积改进DenseNet网络模型,构成D-DenseNet网络模型,并以此代替传统SSD算法中的VGG16网络,从而简化模型,减少运算量,提高检测精度,实现对目标快速且准确的检测。利用相关道路交通图像并结合深度学习中常用的VOC数据集作为样本进行训练和测试,并与Faster R-CNN、YOLOv3及原始SSD模型进行比较,实验结果表明,与其它算法相比,该算法对于高速公路不同环境下无人驾驶汽车的目标检测速度更快,精度更高,具有良好的鲁棒性。

关键词:无人驾驶;目标检测;仿真
中图分类号:TP391 **文献标识码**:B

Research on Object Detection Algorithm for Unmanned Vehicles on Freeway

GE Wen, MA Le, QU Lele
(College of Electronic Information Engineering, Shenyang Aerospace University, Shenyang Liaoning 110136, China)

ABSTRACT: In order to solve the problem of target detection accuracy and speed of unmanned cars in highway environments, this thesis proposes an improved object detection algorithm for the SSD model. The DenseNet network model is improved by integrating Dilated-Convolution to make up a D-DenseNet network model, which is an alternative to the traditional SSD algorithm VGG16 network, so as to predigest the model, reduce the amount of calculations, enhance the detection accuracy, and achieve the rapid and accurate detection. Using relevant road traffic images and combining VOC datasets commonly used in deep learning as samples for training and testing, and comparing with Faster R-CNN, YOLOv3 and primitive SSD models, the experimental results display that the algorithm has faster speed, higher precision and good robustness for target detection of unmanned vehicles on the freeway under different circumstances.

KEYWORDS: Unmanned vehicles; Object detection; Simulation

1 引言

道路交通事故发生频率不断增加使人们逐渐正视交通安全问题,如不采取有效措施来提高交通安全质量,人身安全将会受到巨大的威胁。近年来,由于深度学习技术取得了突破性进展,计算机视觉及工业自动化技术也得到了显著提升。尤其在智能汽车领域,无人驾驶更是得到广泛的关注。在无人驾驶的系统中,目标检测能够为无人驾驶车辆提供安全保障,是重要的关键技术。随着科学技术的发展,深度学习逐渐成为目标检测领域最有效的方法之一,随之而来的卷积神经网络也成为了具有代表性的神经网络之一。卷积神经网络具有较强的自主学习、并行处理和容错能力,其代表算法有:R-CNN[1]、Fast R-CNN[2]、Faster R-CNN[3]、SSD[4]、YOLO[5]等。本文将SSD模型进行了改进,对高速公路环境下无人驾驶中的图像数据进行学习训练及目标检测,并通过仿真实验验证了该模型的检测效果,能够满足对大量图片数据进行准确、高效的目标检测需求,为无人驾驶汽车目标检测技术提供参考价值。

基金项目:国家自然科学基金(61671310);辽宁省兴辽英才计划项目基金(XLYC1907134);辽宁省百千万人才工程项目基金(2018B21)
收稿日期:2021-03-29 修回日期:2021-04-06

2 SSD目标检测算法

截至目前,SSD是最有效的主流目标检测框架之一,它将目的框的输出空间离散成一组具有不同形状和尺寸的默

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

认框。SSD 继承 YOLO 的回归思想,能够一次性完成目标的定位及分类,还继承了 Faster R-CNN 的 Anchor 机制。采用回归思想能够将复杂的神经网络计算化为简单的回归问题,从而提高算法的运行速度及实时性;采用 Anchor 机制能够达到在不同尺寸的特征图上产生不同预测的效果,从而提高检测的精度。与此同时,SSD 采用基于特征金字塔(Pyramidal Feature Hierachy)的检测方法,即能够达到在不同感受野的特征图上预估目标,从而取得良好的检测结果。相比于 Faster R-CNN,SSD 更具有实时性,而相比 YOLO,其 mAP 也得到了显著的提升,其在 VOC2007 数据集上的性能对比如表 1 所示。

表 1　Faster R-CNN、SSD、YOLO 性能对比

Method	tmAP	FPS	batch size	Boxes	Input resolution
Faster R-CNN	73.2	7	1	~6000	~1000×600
Fast YOLO	52.7	155	1	98	448×448
YOLO	66.4	21	1	98	448×448
SSD300	74.3	59	8	8732	300×300
SSD512	76.8	22	8	24564	512×512

2.1　SSD 网络结构

SSD 以检测速度快、准确率高等优点进入大众的视野,是一种单次检测的深度神经网络。它在 YOLO 的基础上进行了改进,将特征提取从整个特征图缩小到局部。SSD 网络结构包括基本网络、辅助卷积层和预测卷积层,并以 VGG16(visual geometry group)作为基本的网络模型,之后在 VGG16 中加入不同的卷积层,从而得到不同尺度的特征图,用于目标检测。VGG16 作为基本模型,首先在 ILSVRCCLS-LOC 数据集上对模型进行预训练,然后利用 DeepLab-LargeFOV 将两个完全连通的层(fc6 和 fc7)替换为普通的 3×3 和 1×1 卷积层(conv6 和 conv7)。在此基础上,再增加几个新的卷积层。其中,在检测初始特征图时需要利用 conv4_3 卷积层,随后从新增加的卷积层中提取部分卷积层用于检测其它特征图,最终产生 1 * 1 的输出。SSD300 网络结构图如图 1 所示。

2.2　默认框(default boxs)尺寸的确定

SSD 采用了 Faster R-CNN 中 anchor 的机制,能够把每一个特征图转化成不同尺寸、不同长宽比的默认框,预测框会以这些默认框为基准进行目标的预测,从而降低样本训练难度。默认框是在某一个特征图上每一点处选取的长宽比不同的选框,以特征图上的每一个点的中心为中心,能够产生一系列同心的默认框。多数情况下,每个特征图将首先设置一些不同大小和不同纵横比的默认框。默认框的设置包括两个方面:尺度和纵横比。在每个特征图中设置的默认框的数量是不同的。每个特征图的默认框的大小遵循线性增加的原则,即默认框的大小随着特征图尺寸的减小而线性增加,其计算公式如式(1)所示

$$s_k = s_{\min} + \frac{s_{\max} - s_{\min}}{m - 1}(k - 1), k \in [1, m] \tag{1}$$

本次实验取,$s_{\min} = 0.2$ 表示最低层获取的默认框尺度为 0.2;$s_{\max} = 0.9$ 表示最高层获取的默认框尺度是 0.9。通过计算,可以得出 6 个特征图的默认框尺度分别为 30,60,111,162,213,264。通常情况下,会设置 5 种宽高比 $a_r \in \{1, 2, 3, \frac{1}{2}, \frac{1}{3}\}$ 来生成默认框,默认框的宽度和高度的计算公式如式(2)和(3)所示

$$w_k^a = s_k \sqrt{a_r} \tag{2}$$

$$h_k^a = s_k / \sqrt{a_r} \tag{3}$$

除此之外,每一个特征图都会有一个 $a_r = 1$ 且尺度为 $s'_k = \sqrt{s_k s_{k+1}}$ 的默认框。

2.3　传统 SSD 模型存在的问题

1) 分类网络输入的唯一来源是不同层的特征图,这样可能会导致同一个物体被不同尺寸的框同时检测出来,从而使检测结果不准确;

2) 模型中正样本与负样本极其不均衡,使模型训练困难,模型的准确度略低;

3) 由于 SSD 模型使用了 conv4_3 低级特征卷积层来检测较小的目标,缺少高级层的语义特征,存在特征提取不完整的问题,导致对小尺寸的物体检测效果不佳;

4) SSD 网络中 default boxs 的基础大小和形状不能直接通过学习获取,必须要手工设置。每一个特征卷积层所使用的默认框的尺寸和形状都是不同的,在后期的调试带来了极大的难度,尤其依赖工程师的经验。

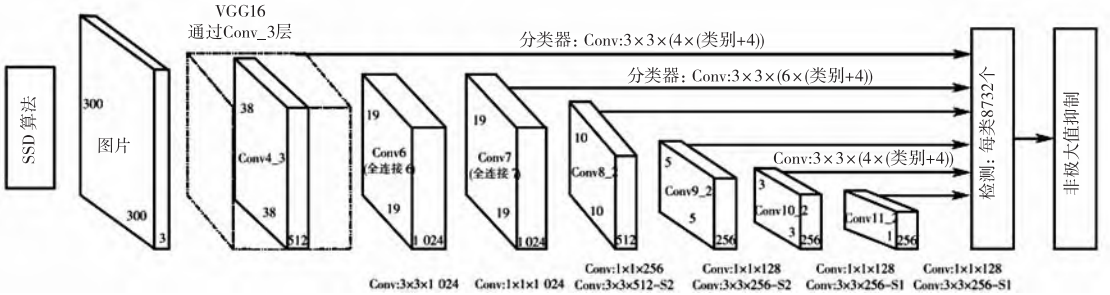


图 1　SSD 网络结构图

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

3 改进 SSD 模型的设计与优化

针对传统 SSD 算法以 VGG16 或 VGG19 作为基础网络，通过不同层的特征来对目标进行检测，使其对尺寸的变化有较好的鲁棒性，但在计算过程中参数较多、计算量较大，容易出现误检、漏检等问题。本文引入 DenseNet 网络模型，加强层与层之间的特征传播，减少参数量的同时也减少了计算量，该网络模型能够有效地缓解梯度消失的问题，使图像特征向更深层次传播。除此之外还结合了空洞卷积（Dilated-Convolution）改进 DenseNet 网络模型，构成 D-DenseNet 网络模型，以此代替传统 SSD 算法中的 VGG16，从而提高模型的检测速度和准确度。

3.1 DenseNet 模型分析

DenseNet 模型在 ResNet 模型基础上做出创新，是近两年新兴的模型结构，由于连接方式的改变，使其相比于 ResNet 在各大数据集上都取得了更好的效果。DenseNet 不通过增加网络层数、扩宽网络结构来提高网络的性能，它通过特征重用和旁路设置，提高了特征的传播效率和利用效率，减少了网络的参数量，又在一定程度上缓解梯度消失的问题，是一种前馈方式的密集连接型网络。

假设输入图片为 X_0，经过一个 M 层的神经网络，其中第 i 层的非线性变化记为 $H_i(*)$，$H_i(*)$ 是各种函数的累加，如：ReLU、BN 或 Conv 等。如果第 i 层的特征输出表示为 X_i，则 DenseNet 的非线性变换方程如式(4)所示：

$$X_i = H_i([X_0, X_1, \cdots, X_{i-1}]) \tag{4}$$

例如在 DenseNet-121 中，第 i 层的非线性变化采用 BN、ReLU 激活函数及 Conv(3×3) 卷积的相结合的连接方式，在加强网络各层之间的信息交换的同时，还提高了网络的训练效率，其网络参数如表 2 所示。

表 2 DenseNet-121 网络参数

Layers	Output size	DenseNet-121
Convolution	112×112	7×7 Conv
Pooling	56×56	3×3 Max Pool
Dense_Block0	56×56	$\begin{pmatrix}1\times1\ \text{Conv}\\6\times6\ \text{Conv}\end{pmatrix}\times6$
Transition Layer0	56×56 28×28	1×1 Conv 2×2 Average Pool
Dense_Block1	28×28	$\begin{pmatrix}1\times1\ \text{Conv}\\3\times3\ \text{Conv}\end{pmatrix}\times12$
Transition Layer1	28×28 14×14	1×1 Conv 2×2 Average Pool
Dense_Block2	14×14	$\begin{pmatrix}1\times1\ \text{Conv}\\3\times3\ \text{Conv}\end{pmatrix}\times24$
Transition Layer2	14×14 7×7	1×1 Conv 2×2 Average Pool
Dense_Block3	7×7	$\begin{pmatrix}1\times1\ \text{Conv}\\3\times3\ \text{Conv}\end{pmatrix}\times16$
Classification Layer	1×1	7×7 Global Average Pool 1000D Fully-Connected Softmax

DenseNet 网络共分为两个组成部分：Dense_Block 和 Transition Layer，每个 Dense_Block 中特征图的尺寸都相同，再对特征图进行拼接。Transition Layer 设置在相邻两个 Dense_Block 之间，负责进行下采样。过渡层包含多种函数的累加、1×1 的卷积层及 2×2 的平均池化层，在网络中，过渡层会把输入到该层的特征图数量减少到原来的一半，从而在一定程度上减少计算量。

3.2 改进 SSD 网络模型

本文用改进的 D-DenseNet-121 代替传统 SSD 模型中用于图像特征提取的映射卷积层，不仅能够提高对目标的识别精度，还能极大程度的提高模型的运算速度。DenseNet-121 首层为 3×3 的卷积层，之后输入的图像数据再经过 4 个 Dense_Block，依次为 6 层、12 层、24 层、16 层，每两个 Dense_Block 之间采用非线性变换 BN+ReLU6+Conv(3×3) 的组合。

为了提高卷积层对小目标的检测精度，引入反向残差结构来减少学习过程中非线性变换在低维度中的特征信息损失。为了避免池化操作中特征信息丢失，本文将采用空洞卷积来替代卷积层中的下采样操作，并将激活函数 ReLU 更换为精度更高的 ReLU6，ReLU6 激活函数数学形式如式(5)所示

$$\text{Re}\,LU6 = \min(6, \max(0, x)) \tag{5}$$

多尺度信息在目标检测中起到至关重要的作用，在空洞卷积中，可以设置不同的参数来扩大感受野，从而获得更多多尺度信息，这样能够精准定位目标，保证检测精度。图 2 显示了卷积核尺寸为 3×3，扩展率为 2 的空洞卷积操作，其感受野的大小为

$$F_2 = (2^{2/2+2} - 1) \times (2^{2/2+2} - 1) = 7 \times 7$$

在模型训练过程中，BN 算法可以加快模型训练的收敛速度，使训练过程更加稳定，防止梯度爆炸和梯度消失的情况发生，还能起到正则化的作用。

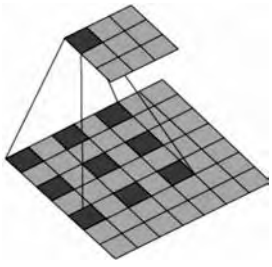


图 2 空洞卷积操作

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

在 DenseNet 之后,有四个卷积层,包含了 1×1 和 3×3 的卷积层。选取最后两层 Dense_Block 和 4 个卷积层进行目标框的选择。优化后的网络模型简单,能够充分利用特征信息,提高小目标的检测精度,优化后的网络模型如图 3 所示。

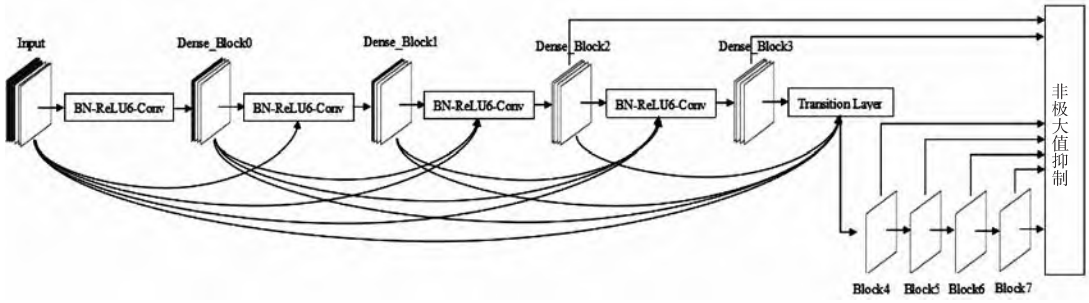


图 3　优化后的网络模型

3.3　损失函数

损失函数可以用来衡量前期估计的值与实验中真实值的误差,在所有算法中损失函数即为最终需要优化的目标函数。

在 SSD 算法中,损失函数由两部分组成,分别为定位损失和置信度损失,如式(6)所示

$$L(x,c,l,g) = \frac{1}{N}(L_{conf}(x,c) + \alpha L_{loc}(x,l,g)) \tag{6}$$

其中,N 为筛选过后默认边界框的数量;c 是经过处理后的定位置信度;l 为预测框的位置预测值;g 就是真实框的位置值;α 为可自己设置的权重系数,通常将其设置为 1;x 为匹配系数,$x \in (0,1)$。当 $x=0$ 时表示预测框与 Ground Truth 不匹配;当 x=1 时表示预测框与 Ground Truth 完全匹配。$L_{conf}(x,c)$ 为置信损失函数;$L_{loc}(x,l,g)$ 为定位损失函数。

定位损失函数 $L_{loc}(x,l,g)$ 是预测框与真实物体框参数之间 *Smooth L1* 损失,其计算公式如式(7)所示

$$\begin{cases} L_{loc}(x,l,g) = \sum_{i \in Pos}^{N} \sum_{m \in \{cx,cy,w,h\}} x_{ij}^{k} smooth_{L_1}(l_i^m - \hat{g}_j^m) \\ smooth_{L_1}(x) = \begin{cases} 0.5x^2 & if\ |x| < 1 \\ |x| - 0.5 & otherwise \end{cases} \end{cases} \tag{7}$$

其中,Pos 为正样本预测框的数量;x_{ij}^{k} 为第 i 个预测框与第 j 个真实框匹配,并且真实框的类别为 k;cx 和 cy 指的是对于宽和高分别为 w 和 h 的默认框的偏移量;l_i^m、$\hat{g}_j^m$ 分别为预测框和真实框的位置参数。由于 x_{ij}^{k} 的存在,所以定位损失只对正样本进行计算。

通常采用 Softmax loss 函数对置信损失 $L_{conf}(x,c)$ 进行计算,如式(8)所示

$$\begin{cases} L_{conf}(x,c) = -\sum_{i \in Pos}^{N} x_{ij}^{p} \log(\hat{c}_i^p) - \sum_{i \in Neg} \log(\hat{c}_i^0) \\ \hat{c}_i^p = \dfrac{\exp(c_i^p)}{\sum_p \exp(c_i^p)} \end{cases} \tag{8}$$

其中,$\hat{c}_i^p$ 是由 Softmax 产生的类别置信度,也就是激活函数;Neg 为负样本的预测框。

目标损失函数对正负样本比例进行了相关控制,不但能够提高算法优化的速度,还能提高训练结果的稳定性。

4　实验与结果分析

4.1　实验平台

本次实验的仿真环境为:计算机 Win10 操作系统,CPU 型号为 Intel(R) Core(TM) i5-9400F。在以上硬件的基础上搭建 Pytorch 机器学习平台,采用 Python3.8 编程语言对相关模型进行训练和测试,从而实现适用于无人驾驶汽车的目标检测算法。

4.2　数据样本结构及模型训练

数据集是通过采集高速公路上道路情况的截图,标注了高速公路上行驶的过程中包含汽车、人、动物等 7 类标签的样本图片,并且结合了目标检测中常用的 V0C2012 数据集中含有相同标签的样本图片,共包含 1150 张图片。为了减少训练中的过拟合现象,提高数据集的质量,本文在此基础上进行数据样本扩展,具体实现方式如表 3 所示。

表 3　数据样本扩展方法

数据样本扩展方法	具体改变
亮度变换	调节图片亮度,亮度值降低 15%
旋转	将图片从 0°旋转到 5°或 10°
剪裁	裁剪图像,裁剪值为原图像的 10%

通过表 3 的方法对数据集进行扩展,扩展后的数据集为 2500 张,扩展数据集由 2000 个训练集和 500 个测试集组成。然后使用 Labellmg 软件对数据集进行标记和注释。

在训练过程中,该算法进行了 40000 次迭代,初始化学习率 base_lr=0.001,批尺寸 batch_size=8,权重衰减因子设为 0.0005,在一定程度上预防训练过程中出现过拟合现象。在数据集训练的过程中,损失值随着迭代次数的增加而收敛。最后,经过 35000 次迭代,训练模型的损失值趋于稳定。

4.3　结果分析

利用训练好的网络模型对数据集进行检测实验。从检测结果中看出,改进后的 SSD 网络模型平均准确率均值达到

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

83.82%,检测速度为42fps。在同一数据集上,对本文提出的改进后的SSD网络模型与其它网络模型、原始SSD网络模型进行测试及对比试验。实验结果如表4、表5所示。

表4　不同网络模型实验结果

网络模型	平均准确率均值mAP/%	平均检测速度fps
Faster R-CNN	78.65	40
SSD(原始)	81.94	45
YOLOv3	82.67	39
SSD(本文)	83.82	42

表5　不同网络模型在不同天气、场景下实验结果

		Faster R-CNN	SSD(原始)	YOLOv3	SSD(本文)
晴天	准确率/%	80.13	82.97	83.86	85.12
	检测速度fps	43	49	42	47
雾天	准确率/%	76.53	80.14	80.75	81.64
	检测速度fps	37	41	35	39
雪天	准确率/%	77.12	80.54	81.14	82.32
	检测速度fps	39	43	38	41
雨天	准确率/%	75.86	79.93	80.03	81.52
	检测速度fps	38	41	37	40

由表4可知,本文改进的SSD模型的mAP为83.82%,Faster R-CNN模型的mAP为78.65%,YOLOv3模型的mAP为82.67%,原始的SSD模型的mAP为81.94%,结果表明改进后的SSD网络模型准确率更高,从检测速度分析,本文的检测速度虽然比原始SSD模型检测速度慢,但能够达到应用要求。因此,改进的SSD模型在无人驾驶中对目标的检测性能更好,四种网络模型在不同天气、场景检测效果如图4所示。



(a) 晴天时检测结果对比



(b) 雾天时检测结果



(c) 雪天时检测结果



(d) 雨天时检测结果



(e) 雾天车速缓慢时检测结果



(f)晴天车速缓慢时检测结果

图4　不同网络模型结果对比

5　结论

为了更好的保证无人驾驶系统的安全问题,本文结合传统的SSD算法与DenseNet模型的优势,引入D-DenseNet网络模型,提高了网络的深度。前置网络采用DenseNet代替传统SSD网络中VGG16进行特征提取,使各层的网络信息得到充分的利用,有益于网络的训练。辅助层网络利用空洞卷积替换下采样操作从而避免信息的丢失,同时还能提高对体积较小物体检测的准确性,进一步提高了系统的检测速度和准确度。实验表明,本文改进后的算法相较于其它算法具有一定的优越性,能够运用于无人驾驶中的目标检测技术中。在接下来的研究中,将增加更多复杂场景的数据集,完善数据集的多样性,进一步提高算法的鲁棒性。

参考文献:

[1] Girshick R,Donahue J,Darrell T等. 用于准确目标检测和语义分割的丰富特征层次结构[C]. IEEE计算机视觉与模式识别会议论文集,2014:580-587.

[2] Girshick R. Fast r-cnn[C]. Proceedings of the IEEE International Conference on Computer Vision,2015:1440-1448.

[3] Ren S,He K,Girshick R,et al. Faster r-cnn:Towards realtime object detection with region proposal networks[C]. Advances in Neural Information Processing Systems,2015:91-99.

[4] Liu W,Anguelov D,P.rhan D,et al. SSD: Single shot multibox detector[C]. European Conference on Computer Vision,2016: 21-37.

[5] Redmon J,Divvala S,Girshick R,et al. You only look once: Unified,real-time object detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2016:779-788.

[6] 徐子豪,黄伟泉,王胤. 基于深度学习的监控视频中多类别车辆检测[J]. 计算机应用,2019,39(3):700-705.

[7] Bochkovskiy A,Wang C,Liao H. YOLOv4: Optimal Speed and Accuracy of Object Detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2020:198-215.

[8] Kan Shichao, Cen Yigang, He Zhihai, et al. Supervised Deep Feature Embedding with Hand Crafted Feature[J]. IEEE Transactions on Image Processing,2019,28(12): 5809-5823.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[9] 陈冰曲,邓涛. 基于改进型 SSD 算法的目标车辆检测研究[J]. 重庆理工大学学报,2019,33(1):58-63,129.
[10] Song Y,Pan Q K,Gao L,et al. Improved non-maximum suppression for object detection using harmony search algorithm[J]. Applied Soft Computing,2019,81:105478.
[11] Sun L,Zhao S,Li G,et al. High accuracy object detection via bounding box regression network[J]. Frontiers of Optoelectronics,2019,12(3):324-331.
[12] 寇大磊,权冀川,张仲伟. 基于深度学习的目标检测框架进展研究[J]. 计算机工程与应用,2019,55(11):25-34.
[13] Biswas D,Su H,Wang C,et al. An automatic traffic density estimation using Single Shot Detection(SSD) and MobileNet-SSD[J]. Physic and Chemistry of the Earth,2019,110:176-84.
[14] Liu Hui,Zhang Li-shua,Shen Yue,et al. Real-time pedestrian detection in orchard based on improved SSD[J]. Transations of the Chinese Society of Agricultural Machinery,2019,50(4):29-36.(in Chinese)
[15] 唐聪,凌永顺,郑科栋,等. 基于深度学习的多视窗 SSD 目标检测方法[J]. 红外与激光工程,2018,3(9):1-9.



[作者简介]

葛　雯(1972-),女(汉族),上海市人,副教授,硕士研究生导师,主要研究领域为图像处理与传输技术、航空电子信息的研究。

马　乐(1997-),女(汉族),辽宁省盘锦市人,硕士研究生,主要研究领域为图像处理与传输技术。

屈乐乐(1983-),男(汉族),河南焦作人,教授,硕士研究生导师,主要研究方向为雷达信号处理与成像技术。

(上接第 52 页)

参考文献:

[1] 蒋栋年,李炜. 基于数据驱动残差评价策略的故障检测方法[J]. 控制与决策,2017,(7): 1181-1188.
[2] 李志军,梁乐乐,韩存武,孙德辉. 基于 PLS 的多采样率过程故障检测及其仿真[J]. 计算机仿真,2016,(10):445-449.
[3] 刘云,尹传环. 基于循环神经网络的通信卫星故障检测[J]. 计算机科学,2020,(2):227-232.
[4] Funa. Z,Ju H. Park,Yajuan.L,Differential feature based hierarchical PCA fault detection method for dynamic fault[J]. Neurocomputing,2016,202:27-35.
[5] Zhichao Li,Xuefeng Yan. Performance-driven ensemble ICA chemical process monitoring based on fault-relevant models[J]. Soft Computing. 2020,24:1289-12302.
[6] Ao Chen,Hongpeng Zhou,Yujian AN,Wei Sun. PCA and PLS monitoring approaches for fault detection of wastewater treatment process[C]. IEEE 25th International Symposium on Industrial Electronics (ISIE),2016:1022-1027.
[7] Lee J M,Yoo C K,Choi S W,etc. Nonlinear process monitoring using kernel principal component analysis [J]. Chemical Engineering Science,2004,59(1):223-234.
[8] M Zhang,Z Ge,Z Song,R Fu. Global-local structure analysis model and its application for fault detection and identification[J]. Industrial & Engineering Chemistry Research,2011,50(11):6837-6848.
[9] Cheng Zhang,Xunian Dai,Xiaofang Zheng,Yuan Li. A Novel Monitoring Strategy Combining the Advantages of NPE and GMM[C]. IEEE Access,2020,8:82989-82997.
[10] Xin Peng,Yang Tang,Wenli Du,Feng Qian. Multimode Process Monitoring and Fault Detection: A Sparse Modeling and Dictionary Learning Method[C]. IEEE Transactions on Industrial Electronics,2017,64(6):4866-4875.
[11] Rui Huang,Guopeng Zhang,Junli Chen. Semi-supervised discriminant Isomap with application to visualization,image retrieval and classification[J]. International Journal of Machine Learning and Cybernetics,2019,10: 1269-1278.
[12] Chengjun Zhan,Shuanghong Li,Yupu Yang. Enhanced Fault Detection Based on Ensemble Global-Local Preserving Projections with Quantitative Global-Local Structure Analysis [J]. Ind. Eng. Chem. Res,2017,56(38): 10743-10755.
[13] Qingchao Jiang,Xuefeng Yan. Probabilistic weighted NPE-SVDD for chemical process monitoring [J]. Control Engineering Practice,2014,28:74-89.
[14] Lee D D,Seimg H S. Learning the parts of objects by non-negative matrix factorization [J]. Nature,1999,401(6755):788-791.
[15] Hoyer P O. Non-negative matrix factorization with sparseness constraints[J]. The Journal of Machine Learning Research,2004,5:1457-1469.
[16] Zheng Y,Yang J,Zhu Y. Initialization enhancer for non-negative matrix factorization[J]. Engineering Applications of Artificial Intelligence,2007,20:101-110.
[17] Hsu C C,Chen L S,Liu C H. A process monitoring scheme based on independent component analysis and adjusted outliers[J]. International Journal of Production Research,2010,48(6).



[作者简介]

彭　艺(1983-),女(汉族),河南太康人,博士研究生,高级工程师,主要研究领域为卫星数据处理。

冯小虎(1970-),男(汉族),北京人,正高级工程师,主要研究领域为卫星遥感技术。

贾树泽(1982-),男(汉族),黑龙江哈尔滨人,硕士研究生,高级工程师,主要研究领域为卫星遥感信息处理。

韩　琦(1979-),男(汉族),山西阳城人,硕士研究生,高级工程师,主要研究领域为气象电子(通信作者)。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net